


LAPORAN *PROJECT* MACHINE LEARNING
ANALISIS PENGARUH STRATEGI PEMASARAN TERHADAP
PENDAPATAN PENJUALAN PADA MARKETING SALES DATASET



Oleh Kelompok B:

1. Zalma Hasna Solikhin (K1D024004)
2. Salman Alfarisy (K1D024010)
3. Natasya Jamila Mapaza (K1D024016)
4. Galih Tri Prasetyo (K1D024028)
5. Arroja Aliya Fadhillah (K1D024037)

Disusun untuk memenuhi tugas terstruktur:

Mata kuliah : Machine Learning

Dosen Pengampu : Lutfiah Maharani Siniwi, S.Stat., M.Stat.

KEMENTERIAN PENDIDIKAN TINGGI, SAINS DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO
2026

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, laporan *project* Machine Learning yang berjudul “Analisis Pengaruh Strategi Pemasaran Terhadap Pendapatan Penjualan Pada Marketing Sales Dataset ” dapat diselesaikan dengan baik. Laporan ini disusun untuk memenuhi tugas mata kuliah sekaligus sebagai bentuk penerapan materi Machine Learning yang telah dipelajari selama masa perkuliahan.

Dalam *project* ini, dilakukan penerapan konsep *data mining* dan *machine learning* pada data penjualan untuk membangun model prediksi pendapatan penjualan (*sales revenue*). Tahapan yang dilakukan meliputi eksplorasi data, *preprocessing*, pembangunan model prediksi, serta evaluasi performa model untuk memperoleh model dengan kemampuan prediksi yang baik. Melalui analisis yang dilakukan, diharapkan hasil yang diperoleh dapat memberikan gambaran mengenai penerapan metode prediksi dalam mendukung pengambilan keputusan yang lebih efektif.

Keberhasilan penyusunan proyek ini tidak terlepas dari dukungan, bantuan, serta kontribusi dari berbagai pihak. Oleh karena itu, kami menyampaikan terima kasih kepada Ibu Lutfiah Maharani Siniwi, S.Stat., M.Stat. selaku dosen pengampu mata kuliah Machine Learning yang telah memberikan arahan, bimbingan, dan ilmu selama proses pembelajaran. Kami juga mengucapkan terima kasih kepada seluruh rekan yang telah memberikan bantuan, saran, maupun masukan selama proses pengerjaan proyek ini.

Penulis menyadari bahwa dalam penyusunan makalah ini masih terdapat berbagai kekurangan. Oleh karena itu, kritik dan saran yang bersifat membangun sangat diharapkan sebagai bahan evaluasi dan perbaikan di masa mendatang. Penulis berharap makalah ini dapat memberikan manfaat serta menambah wawasan bagi pembaca mengenai penerapan analisis data dan *machine learning* dalam membangun model prediksi pada bidang pemasaran dan penjualan.

Purwokerto, 26 Juni 2026

Penyusun

DAFTAR ISI

KATA PENGANTAR.....	i
DAFTAR ISI.....	ii
DAFTAR TABEL	iii
DAFTAR GAMBAR.....	iv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian.....	2
1.4 Manfaat Penelitian.....	3
BAB II TINJAUAN DATASET.....	4
2.1 Sumber Data	4
2.2 Deskripsi Dataset.....	4
2.3 Pemilihan Target dan Fitur	6
BAB III METODOLOGI.....	7
3.1 Alur Penelitian.....	7
3.2 Eksplorasi Data.....	7
3.3 Prapemrosesan Data	9
3.5 Pembagian Data.....	11
3.6 Pemodelan	11
3.7 Metrik Evaluasi.....	14
BAB IV HASIL DAN PEMBAHASAN	17
4.1 Eksplorasi Data (EDA).....	17
4.2 Prapemrosesan Data	21
4.3 Pemodelan	24
4.4 Analisis dan Evaluasi Model Terpilih	27
BAB V PENUTUP.....	32
5.1 Kesimpulan.....	32
5.2 Keterbatasan Analisis	33
5.3 Saran	34
LAMPIRAN.....	36

DAFTAR TABEL

Tabel 2.1 Deskripsi Variabel pada Marketing Sales Dataset	5
Tabel 3.1 Metrik evaluasi beserta interpretasinya.....	16
Tabel 4.1 Statistika Deskriptif Variabel Numerik Utama	17
Tabel 4.2 Statistika Deskriptif Fitur Numerik setelah Standarisasi	23
Tabel 4.3 Perbandingan Metrik Evaluasi	24
Tabel 4.4 Perbandingan Evaluasi Sebelum dan Sesudah Hyperparameter Tuning	26

DAFTAR GAMBAR

Gambar 4.1 Visualisasi Histogram pada Variabel Target.....	18
Gambar 4.2 Visualisasi BoxPlot pada Variabel Target.....	19
Gambar 4.3 Visualisasi Heatmap Korelasi.....	20
Gambar 4.4 Perbandingan Plot Prediksi dan Aktual.....	27
Gambar 4.5 Visualisasi Residual Model XGBoost Tuned.....	28
Gambar 4.6 Visualisasi Tingkat Pengaruh Fitur terhadap Variabel Target	29
Gambar 4.7 1Visualisasi Learning Curve Model XGBoost Tuned.....	30

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pada era digital, persaingan antarperusahaan semakin meningkat untuk menarik pelanggan dan meningkatkan penjualan melalui berbagai strategi pemasaran, seperti pemasangan iklan, pemberian diskon, promosi produk, penggunaan media sosial, maupun peningkatan kualitas pelayanan. Namun, tidak semua strategi memberikan hasil yang sama terhadap pendapatan. Oleh karena itu, perusahaan perlu mengetahui strategi mana yang paling berpengaruh agar biaya pemasaran yang dikeluarkan dapat digunakan secara lebih efektif dan efisien.

Seiring berkembangnya teknologi, perusahaan menghasilkan banyak data aktivitas pemasaran dan penjualan yang dapat dimanfaatkan untuk menganalisis hubungan tersebut. Melalui analisis data, perusahaan dapat mengambil keputusan yang lebih tepat berdasarkan informasi riil, bukan sekadar perkiraan. Kendala yang sering dihadapi saat ini adalah akumulasi data yang besar tersebut sering kali hanya menjadi tumpukan arsip tanpa diekstrak pengetahuannya secara mendalam. Padahal, fluktuasi pasar yang dinamis menuntut manajemen untuk mengidentifikasi pola tersembunyi dari perilaku konsumen dengan cepat. Penelitian ini menggunakan *Marketing Sales Dataset* yang mencakup beberapa variabel prediktor, seperti anggaran pemasaran, biaya iklan online dan offline, jumlah promosi, persentase diskon, jumlah tenaga penjualan, tingkat kepuasan pelanggan, dan jumlah kunjungan website, dengan target utama yaitu pendapatan penjualan (*sales revenue*).

Karena pendapatan penjualan berupa data numerik, penelitian ini menerapkan metode regresi untuk mengetahui hubungan antarvariabel sekaligus memprediksi besarnya pendapatan berdasarkan faktor yang tersedia. Pendekatan berbasis data ini diharapkan mampu meminimalisasi subjektivitas dalam alokasi anggaran serta memberikan estimasi pendapatan yang lebih terukur. Berdasarkan uraian tersebut, penelitian berjudul "Analisis Pengaruh Strategi Pemasaran terhadap Pendapatan Penjualan pada Marketing Sales Dataset" dilakukan untuk menganalisis pengaruh strategi pemasaran serta membangun model regresi prediksi yang baik. Hasil penelitian diharapkan dapat memberikan informasi bermanfaat bagi perusahaan dalam menyusun strategi pemasaran yang optimal serta menjadi landasan strategis dalam memenangkan persaingan bisnis di masa depan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana pengaruh strategi pemasaran terhadap pendapatan penjualan pada Marketing Sales Dataset?
2. Faktor-faktor pemasaran apa saja yang memiliki pengaruh signifikan terhadap pendapatan penjualan?
3. Bagaimana hubungan antara variabel-variabel pemasaran dengan pendapatan penjualan yang dihasilkan?
4. Model regresi machine learning manakah yang memiliki performa terbaik dalam memprediksi pendapatan penjualan berdasarkan nilai evaluasi model?
5. Seberapa baik model regresi yang dibangun dalam memprediksi pendapatan penjualan pada data yang digunakan?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan dari penelitian ini adalah:

1. Menganalisis pengaruh strategi pemasaran terhadap pendapatan penjualan pada Marketing Sales Dataset.
2. Mengidentifikasi faktor-faktor pemasaran yang paling berpengaruh terhadap pendapatan penjualan.
3. Menganalisis hubungan antara variabel-variabel pemasaran dengan pendapatan penjualan yang dihasilkan.
4. Membangun dan membandingkan beberapa model regresi machine learning untuk memprediksi pendapatan penjualan.
5. Menentukan model regresi terbaik berdasarkan hasil evaluasi menggunakan metrik yang sesuai, seperti MAE (Mean Absolute Error), RMSE (Root Mean Square Error), dan R^2 (Coefficient of Determination).

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat bagi berbagai pihak, antara lain:

1. Bagi Perusahaan

Hasil analisis ini dapat digunakan sebagai bahan pertimbangan utama dalam menentukan arah kebijakan strategi pemasaran yang lebih efektif untuk meningkatkan pendapatan penjualan secara signifikan. Selain itu, perusahaan dapat mengetahui faktor-faktor pemasaran yang memiliki pengaruh paling dominan sehingga manajemen mampu mengalokasikan sumber daya serta anggaran operasional secara lebih optimal dan tepat sasaran.

2. Bagi Akademisi

Analisis ini diharapkan dapat menjadi salah satu referensi ilmiah dan sumber informasi yang valid bagi mahasiswa, dosen, maupun peneliti lain yang ingin mendalami penerapan *machine learning* di ranah praktis. Pembahasan dalam penelitian ini dapat memperkaya literatur mengenai studi komparasi model, khususnya implementasi metode regresi linier dan algoritma berbasis pohon untuk menyelesaikan masalah bisnis. Lebih jauh lagi, hasil studi ini dapat memicu diskusi akademik baru serta menjadi batu pijakan untuk dikembangkan ke dalam cakupan metodologi yang lebih luas.

3. Bagi Peneliti

Analisis ini dapat menambah pengetahuan serta pengalaman langsung bagi peneliti dalam menerapkan tahapan *machine learning* yang sistematis dan sesuai standar industri. Proses yang dilalui memberikan pemahaman mendalam mulai dari teknik eksplorasi data, prapemrosesan data yang kompleks, mitigasi *overfitting*, hingga evaluasi performa model untuk memecahkan kasus riil.

4. Bagi Pengembangan Ilmu Pengetahuan

Penelitian ini diharapkan dapat memberikan kontribusi nyata terhadap akselerasi pengembangan ilmu pengetahuan, khususnya di bidang *data science* dan manajemen pemasaran berbasis digital. Penelitian ini membuktikan secara empiris bagaimana integrasi antara teori statistika multivariat dan algoritma komputasi modern dapat menjadi alat bantu pengambilan keputusan yang akurat. Hal ini memperkuat pergeseran paradigma keilmuan yang menuntut setiap perumusan strategi bisnis untuk selalu berpijak pada validasi data yang objektif.

BAB II

TINJAUAN DATASET

2.1 Sumber Data

Data yang digunakan dalam penelitian ini adalah Marketing Sales Dataset, yaitu kumpulan data sekunder yang diperoleh dari platform penyedia dataset terbuka Kaggle dengan judul “Marketing_Sales_Dataset” yang dipublikasikan oleh pengguna @abdelfattahibrahim. Dataset ini bersifat sintetis (*synthetic dataset*), artinya data dihasilkan secara terprogram menggunakan distribusi statistik dan logika domain pemasaran tertentu, sehingga tidak merepresentasikan data transaksi dari perusahaan, individu, atau entitas tertentu secara nyata. Sifat sintetis ini menjadikan dataset cocok untuk tujuan pembelajaran dan praktik penerapan metode *machine learning*, khususnya pada kasus regresi prediksi pendapatan penjualan.

Dataset asli yang dipublikasikan pada platform tersebut memiliki ukuran sebanyak 60.000 observasi dengan 22 fitur. Pada penelitian ini, data yang digunakan merupakan bagian dari dataset tersebut yang terdiri dari 5.000 observasi dan 23 kolom (termasuk kolom *sales_revenue* sebagai target), yang disimpan dalam format berkas Microsoft Excel (.xlsx) dengan nama *marketing_dataset.xlsx*. Pembatasan menjadi 5.000 observasi ini dilakukan demi efisiensi waktu komputasi selama proses *hyperparameter tuning* dan *cross validation*, dengan ukuran sampel yang dinilai sudah cukup representatif untuk melatih model secara stabil.

2.2 Deskripsi Dataset

Dataset yang digunakan terdiri dari 5.000 baris observasi dan 23 kolom variabel. Berdasarkan karakteristiknya, komposisi tipe data pada dataset ini meliputi 7 variabel bertipe integer (*int64*), 10 variabel bertipe decimal atau kontinu (*float64*), dan 6 variabel bertipe kategorikal atau teks (*object*). Secara kronologis, dataset ini merepresentasikan aktivitas penjualan dan pemasaran yang berlangsung selama empat tahun pengamatan sejak 1 Januari 2020 hingga 31 Desember 2023. Cakupan wilayah operasional yang tercatat di dalam data mencakup tujuh kota besar, yaitu Riyadh, Dubai, Cairo, Casablanca, Alexandria, Kuwait, dan Amman. Variasi yang terbentuk menghasilkan tingkat keragaman data yang representatif untuk mendukung pemodelan pengaruh strategi pemasaran terhadap pendapatan penjualan (*sales revenue*). Keterangan lebih rinci mengenai definisi operasional dari setiap variabel disajikan pada Tabel 2.1.

Tabel 2.1 Deskripsi Variabel pada Marketing Sales Dataset

No	Nama Variabel	Tipe Data	Keterangan
1	id	int64	Penanda (identifikasi) unik untuk setiap baris data, bernilai 1 sampai 5000.
2	date	object	Tanggal terjadinya transaksi penjualan, periode 2020-2023.
3	region	object	Wilayah/kota tempat transaksi berlangsung (7 kategori).
4	sales_channel	object	Kanal penjualan yang digunakan (5 kategori: Retail Store, Online, Direct Sales, Wholesale, Social Media).
5	product_category	object	Kategori produk yang terjual (5 kategori: Cosmetics, Electronics, Food & Beverage, Home Appliances, Clothing).
6	customer_segment	object	Segmen pelanggan (4 kategori: Regular, New, Corporate, VIP).
7	season	object	Musim atau kuartal terjadinya transaksi (Q1–Q4).
8	marketing_budget_usd	float64	Total anggaran pemasaran yang dikeluarkan (USD).
9	ad_spend_online_usd	float64	Biaya iklan melalui kanal online (USD).
10	ad_spend_offline_usd	float64	Biaya iklan melalui kanal offline (USD).
11	num_promotions	int64	Jumlah promosi yang dijalankan.
12	discount_percentage	float64	Persentase diskon yang diberikan.
13	num_sales_representatives	int64	Jumlah tenaga penjual yang terlibat.
14	customer_age	int64	Usia pelanggan (tahun).
15	customer_satisfaction_score	float64	Skor kepuasan pelanggan (skala 1-5).
16	competitor_price_index	float64	Indeks perbandingan harga terhadap kompetitor.
17	website_traffic	int64	Jumlah kunjungan pada website perusahaan.
18	conversion_rate	float64	Tingkat konversi pengunjung menjadi pembeli.
19	email_open_rate	float64	Tingkat pembukaan email pemasaran.
20	social_media_followers	int64	Jumlah pengikut media sosial perusahaan.
21	days_since_last_purchase	float64	Jumlah hari sejak pembelian terakhir.
22	num_previous_purchases	int64	Jumlah pembelian yang pernah dilakukan sebelumnya.
23	sales_revenue_usd	float64	Pendapatan penjualan (variabel target penelitian.)

2.3 Pemilihan Target dan Fitur

Berdasarkan rumusan masalah dan tujuan penelitian, variabel `sales_revenue_usd` ditetapkan sebagai variabel target karena merupakan ukuran utama keberhasilan strategi pemasaran yang ingin diprediksi. Karena `sales_revenue_usd` berskala numerik dan kontinu, permasalahan penelitian ini dikategorikan sebagai permasalahan regresi, sehingga seluruh variabel lain dalam dataset berpotensi digunakan sebagai variabel prediktor (fitur).

Sebelum dilakukan seleksi fitur lebih lanjut, dua variabel dikeluarkan terlebih dahulu dari kandidat fitur, yaitu:

1. Kolom `id`, karena bersifat sebagai penanda unik baris data yang tidak memiliki keterkaitan substansial dengan pendapatan penjualan.
2. Kolom `date`, karena informasi waktu yang relevan telah terwakili secara teragregasi melalui variabel `season` (kuartal), sehingga penggunaan variabel `date` dalam format aslinya berisiko menimbulkan redundansi informasi serta memerlukan penanganan format yang lebih kompleks.

Dengan demikian, analisis ini menetapkan `sales_revenue_usd` sebagai variabel target tunggal yang akan diprediksi. Sementara itu, seluruh variabel lain yang tersedia di dalam dataset di luar kolom `id` dan `date` yang telah dieliminasi akan dikategorikan sebagai variabel prediktor (fitur). Sebanyak 20 variabel prediktor inilah yang kemudian akan masuk ke tahapan seleksi fitur berikutnya guna menguji tingkat korelasi dan multikolinieritasnya sebelum dilakukan proses pemodelan.

BAB III METODOLOGI

3.1 Alur Penelitian

Penelitian ini menggunakan pendekatan regresi untuk memprediksi variabel target berupa nilai kontinu berdasarkan sejumlah variabel prediktor. Secara umum, alur penelitian terdiri dari tahap eksplorasi data, prapemrosesan, rekayasa fitur, pemodelan, dan evaluasi. Setiap tahap dilaksanakan secara sistematis dan berurutan guna memastikan kualitas model yang dihasilkan.

Alur penelitian diawali dengan pengumpulan dan eksplorasi data untuk memahami karakteristik dataset. Selanjutnya dilakukan prapemrosesan data untuk menangani missing value, encoding variabel kategorik, normalisasi, dan penanganan outlier. Setelah data siap, dilakukan rekayasa fitur dan seleksi fitur, diikuti pembagian data menjadi data latih dan data uji. Tahap akhir meliputi pemodelan menggunakan berbagai algoritma regresi, *hyperparameter tuning*, serta evaluasi performa model.

3.2 Eksplorasi Data

Tahap eksplorasi data (Exploratory Data Analysis/EDA) merupakan langkah awal yang krusial dalam penelitian ini. EDA bertujuan untuk memahami struktur, distribusi, dan pola yang terdapat dalam dataset sebelum dilakukan pemodelan lebih lanjut.

3.2.1 Statistik Deskriptif

Statistik deskriptif digunakan untuk meringkas karakteristik utama dari setiap variabel dalam dataset. Analisis yang dilakukan meliputi:

- a. Ukuran pemusatan: mean, median, dan modus untuk mengetahui nilai sentral dari setiap fitur.
- b. Ukuran penyebaran: standar deviasi, varians, rentang (range), serta kuartil (Q1, Q2, Q3) untuk mengukur variabilitas data.
- c. Ukuran bentuk distribusi: skewness (kemencengan) dan kurtosis untuk menilai simetri dan ekor distribusi.
- d. Jumlah observasi, jumlah missing value, dan tipe data setiap variabel.

Hasil statistik deskriptif memberikan gambaran awal mengenai skala data, kemungkinan adanya outlier, serta kebutuhan transformasi data sebelum pemodelan.

3.2.2 Visualisasi Data

Visualisasi data dilakukan untuk memperjelas pola dan hubungan antar variabel yang sulit teridentifikasi hanya melalui statistik numerik. Beberapa teknik visualisasi yang digunakan antara lain:

- a. Histogram: digunakan untuk menampilkan distribusi setiap variabel numerik.
- b. Boxplot: digunakan untuk mengidentifikasi sebaran data dan potensi outlier pada masing-masing fitur.
- c. Scatter plot: digunakan untuk mengamati hubungan linear antara variabel prediktor dengan variabel target.
- d. Heatmap korelasi: digunakan untuk menampilkan matriks korelasi antar variabel secara visual, memudahkan identifikasi multikolinearitas.

3.2.3 Identifikasi Masalah

Berdasarkan hasil statistik deskriptif dan visualisasi, dilakukan identifikasi terhadap berbagai masalah yang dapat memengaruhi performa model regresi, di antaranya:

- a. *Missing value*: keberadaan nilai yang hilang pada satu atau lebih fitur yang perlu ditangani sebelum pemodelan.
- b. *Outlier*: nilai ekstrim yang berada jauh dari distribusi umum data dan berpotensi mendistorsi hasil estimasi parameter model.
- c. Ketidakseimbangan skala fitur: perbedaan skala yang signifikan antar variabel prediktor yang dapat mempengaruhi performa model berbasis gradien.
- d. Multikolinearitas: hubungan linear yang kuat antar variabel prediktor yang dapat menyebabkan instabilitas koefisien regresi.

3.2.4 Insight Awal

Insight awal diturunkan secara langsung dari hasil eksplorasi sebagai dasar pengambilan keputusan taktis pada tahap prapemrosesan dan pemodelan. Temuan yang diharapkan mencakup identifikasi fitur-fitur yang memiliki korelasi kuat terhadap variabel target, penentuan variabel yang memerlukan transformasi akibat distribusi tidak normal, serta pemetaan awal mengenai kompleksitas hubungan antarvariabel. Melalui pemahaman komprehensif terhadap karakteristik data ini, peneliti dapat mengantisipasi risiko bias sejak dini serta merancang arsitektur model yang lebih adaptif.

3.3 Prapemrosesan Data

Prapemrosesan data merupakan tahap transformasi data mentah menjadi format yang siap digunakan untuk pemodelan. Kualitas data secara langsung mempengaruhi performa model regresi yang dibangun, sehingga tahap ini dilaksanakan dengan cermat dan sistematis.

3.3.1 Feature Selection

Tahapan seleksi fitur (*feature selection*) dilakukan dengan tujuan untuk mereduksi dimensi data, mengeliminasi fitur yang tidak informatif, serta meningkatkan efisiensi komputasi model tanpa mengurangi performa prediksi secara signifikan. Proses seleksi fitur dalam penelitian ini diterapkan melalui dua tahapan penyaringan utama berbasis analisis matriks korelasi *Pearson*.

a. Eliminasi Multikolinearitas Antarvariabel Independen

Tahap pertama difokuskan untuk mendeteksi adanya gejala multikolinieritas, yaitu kondisi di mana terdapat hubungan linear atau korelasi yang terlalu kuat antar-variabel prediktor (X). Batas ambang (*threshold*) nilai koefisien korelasi yang ditetapkan dalam penelitian ini adalah sebesar 0,95 (95%). Apabila ditemukan sepasang atau sekelompok variabel independen yang memiliki nilai korelasi melebihi batas $r > 0,95$, maka salah satu variabel akan dipertahankan sementara variabel lainnya yang redundan akan dikeluarkan (*drop*) dari *dataset*. Langkah ini krusial untuk mencegah terjadinya gangguan instabilitas pada estimasi parameter model serta mengurangi kompleksitas arsitektur pohon keputusan yang tidak perlu.

b. Eliminasi Fitur Berdasarkan Korelasi terhadap Variabel Target

Setelah penyaringan multikolinieritas selesai, tahap kedua dilanjutkan dengan menguji kekuatan hubungan linear antara masing-masing variabel independen tersisa terhadap variabel dependen atau target (*sales_revenue_usd*). Batas ambang korelasi minimal terhadap variabel target (Y) ditetapkan sebesar 0,05 (5%). Variabel independen yang mencatatkan nilai koefisien korelasi sangat lemah, yaitu di bawah nilai ambang batas tersebut ($r < 0,05$), akan dieliminasi dari sistem pemodelan. Penghapusan ini didasarkan pada asumsi bahwa fitur dengan korelasi yang terlalu mendekati nol tidak memberikan kontribusi informasi yang bermakna dalam membantu model menangkap variansi nilai pendapatan.

3.3.2 Identifikasi *Missing Value*

Tahapan identifikasi nilai hilang (*missing value*) dilakukan untuk memastikan integritas dan kualitas data sebelum melangkah ke proses pemodelan. Adanya nilai kosong di dalam dataset dapat menghambat kinerja algoritma serta berpotensi menimbulkan bias pada hasil analisis statistik. Proses pengecekan ini diimplementasikan secara terprogram menggunakan bahasa Python melalui pemanggilan fungsi `df.isnull().sum()`. Fungsi tersebut bekerja dengan cara memetakan setiap sel di dalam repositori data (*dataframe*) untuk mendeteksi keberadaan nilai bertipe Null atau NaN (*Not a Number*), kemudian mengakumulasikan total kemunculan nilai hilang tersebut secara spesifik pada masing-masing kolom variabel prediktor maupun variabel target.

3.3.3 Identifikasi Duplikasi Data

Proses identifikasi duplikasi data merupakan bagian penting dari tahapan prapemrosesan data (*data preprocessing*) yang bertujuan untuk menjamin keaslian dan keunikan setiap baris informasi di dalam *dataset*. Keberadaan baris data yang berulang secara identik berpotensi menyebabkan distorsi pada perhitungan statistik, memperlambat waktu komputasi, serta memicu masalah *overfitting* karena model mempelajari bobot dari sampel data yang sama secara berulang-ulang. Pemeriksaan ini diimplementasikan secara terprogram menggunakan bahasa Python melalui fungsi `df.duplicated().sum()`. Fungsi tersebut mengevaluasi seluruh baris di dalam data repositori (*dataframe*) untuk mendeteksi kesamaan nilai di setiap kolom secara simultan, lalu menjumlahkan total baris duplikat yang ditemukan.

3.3.3 Transformasi Skala Data (Standarisasi)

Tahapan transformasi skala fitur (*feature scaling*) bertujuan untuk menyamakan rentang nilai dari seluruh variabel prediktor numerik. Tanpa adanya penskalaan, variabel dengan rentang nilai yang besar dapat mendominasi proses pembelajaran model dan mengabaikan variabel dengan rentang nilai lebih kecil. Dalam analisis ini, metode transformasi yang dipilih adalah standarisasi *Robust Scaler* yang didasarkan pada karakteristik *dataset* pemasaran yang digunakan, di mana masih terdapat *outlier* yang signifikan pada beberapa variabel. Berikut adalah rumus Standarisasi Robust.

$$X_{scaled} = \frac{X - Median}{IQR}$$

Berbeda dengan metode standarisasi konvensional (*Standard Scaler*) yang menggunakan nilai rata-rata (*mean*) dan simpangan baku (*standard deviation*) yang sangat sensitif terhadap pencilan, *Robust Scaler* bekerja dengan memanfaatkan statistik deskriptif yang lebih stabil, yaitu nilai tengah (*median*) dan Jangkauan Antarkuartil (*Interquartile Range* atau IQR). Secara matematis, proses penskalaan ini dilakukan dengan mengurangi setiap nilai asli fitur dengan *median*, kemudian membaginya dengan nilai IQR (selisih antara Kuartil 3 dan Kuartil 1). Melalui pendekatan ini, pemusatan dan penskalaan data dilakukan secara independen tanpa terdistorsi oleh keberadaan data ekstrem. Dengan demikian, karakteristik sebaran asli data normal tetap terjaga dengan baik, sehingga mampu menghasilkan masukan data yang lebih objektif dan tangguh (*robust*).

3.5 Pembagian Data

Untuk mengevaluasi performa model secara objektif pada data yang belum pernah dilihat sebelumnya, *dataset* ini dibagi menjadi dua bagian utama, yaitu data latih (*training*) dan data uji (*test*). Pembagian data dilakukan menggunakan metode *train-test split* dengan proporsi acak terkontrol sebesar 80:20. Melalui rasio ini, sebesar 80% dari total keseluruhan sampel dialokasikan untuk melatih algoritma dalam mengenali pola data pemasaran, sedangkan 20% sisanya diisolasi sepenuhnya sebagai data uji akhir untuk mengukur kemampuan generalisasi model.

Selanjutnya, guna mengoptimalkan tahapan pemilihan model serta *hyperparameter tuning*, analisis ini menerapkan teknik *K-Fold Cross Validation* dengan nilai $K=5$ yang dieksekusi khusus pada subset data latih. Mekanisme ini bekerja dengan membagi data latih menjadi 5 bagian (*fold*) berukuran sama besar secara acak. Dalam setiap iterasi proses pemantapan model, satu bagian akan bertindak sebagai data validasi untuk menguji parameter sementara, sementara 4 bagian lainnya berfungsi sebagai basis pelatihan. Pendekatan ini diulang sebanyak 5 kali sehingga setiap bagian merasakan peran sebagai data uji internal. Penerapan metode ini krusial untuk menghasilkan estimasi performa model yang lebih stabil, mengurangi varians hasil, serta memastikan model terhindar dari ketergantungan pada satu partisi data tertentu.

3.6 Pemodelan

Tahap pemodelan merupakan inti dari penelitian ini, di mana berbagai algoritma regresi dibangun, dilatih, dan dievaluasi. Pemodelan dilakukan secara bertahap, dimulai dari baseline model sederhana hingga model yang lebih kompleks dengan tuning hyperparameter.

3.6.1 Baseline Model

Baseline model berfungsi sebagai tolok ukur awal untuk mengukur sejauh mana model yang lebih kompleks dapat meningkatkan performa prediksi. Dalam penelitian ini, dua model baseline yang digunakan adalah:

- a. Mean Predictor: Model paling sederhana yang memprediksi variabel target dengan nilai rata-rata dari data latih untuk setiap observasi baru. Model ini memberikan batas bawah (lower bound) performa yang harus dilampaui oleh setiap model yang dibangun.
- b. Regresi Linear Berganda: Model ini mengasumsikan hubungan linear antara prediktor dan variabel target, serta memberikan interpretasi koefisien yang mudah dipahami.

Performa baseline model diukur menggunakan metrik yang sama dengan model utama, sehingga perbandingan yang adil dan konsisten dapat dilakukan.

3.6.2 Algoritma yang Digunakan

Penelitian ini mengimplementasikan dan membandingkan beberapa algoritma regresi dari berbagai kategori, mulai dari model linear hingga model ensemble berbasis pohon keputusan. Berikut adalah deskripsi setiap algoritma yang digunakan:

- a. Lasso Regression

Lasso (Least Absolute Shrinkage and Selection Operator) menggunakan penalti L_1 yang mendorong beberapa koefisien menjadi tepat nol, sehingga secara implisit melakukan seleksi fitur. Fungsi loss Lasso didefinisikan sebagai:

$$L(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

Keunggulan Lasso dibandingkan Ridge adalah kemampuannya menghasilkan model yang *sparse* (jarang) dengan hanya mempertahankan fitur yang paling relevan, sehingga model lebih mudah diinterpretasikan. Melalui regularisasi ini, Lasso mampu mereduksi dimensi data secara otomatis dengan mengeliminasi variabel independen yang memiliki kontribusi linier sangat rendah terhadap target prediksi.

- b. Random Forest Regressor

Random Forest adalah metode ensemble yang membangun sejumlah besar Decision Tree secara paralel menggunakan teknik bootstrap aggregating (bagging) dan pemilihan fitur acak. Prediksi akhir diperoleh dari rata-rata prediksi seluruh pohon.

Pengacakan ganda (pada sampel data dan pemilihan fitur) menjadikan Random Forest sangat robust terhadap overfitting dan mampu menangkap hubungan non-linear serta interaksi antar fitur secara efektif.

c. XGBoost (Extreme Gradient Boosting)

XGBoost (Extreme Gradient Boosting) pada dasarnya adalah versi modern dari algoritma *Gradient Boosting* yang telah ditingkatkan kecepatannya dan dioptimalkan kinerjanya. Algoritma ini bekerja seperti sebuah tim yang belajar dari kesalahan: ia membangun serangkaian pohon keputusan (*decision trees*) secara bertahap, di mana setiap pohon baru dirancang khusus untuk mengoreksi kesalahan prediksi yang dibuat oleh pohon sebelumnya.

Keunggulan utama XGBoost terletak pada kecerdasan sistem bawaannya yang serba otomatis. Algoritma ini dilengkapi dengan fitur regularisasi (L_1 dan L_2) yang berfungsi sebagai "rem" otomatis agar model tidak terlalu kompleks sehingga terhindar dari *overfitting* (kondisi di mana model terlalu menghafal data latihan). Selain itu, XGBoost mampu mendeteksi dan menangani data yang kosong (*missing value*) secara mandiri, mempercepat proses hitung lewat pembagian tugas komputer (*komputasi paralel*), serta melakukan pemangkasan (*pruning*) pada cabang-cabang pohon keputusan yang dinilai tidak memberikan keuntungan atau kontribusi informasi yang berarti. Berkat kombinasi fitur tersebut, XGBoost sangat efisien dalam mengolah data berukuran besar dan kerap menjadi algoritma andalan dengan performa terbaik di berbagai kompetisi sains data.

3.6.3 Hyperparameter Tuning

Hyperparameter tuning dilakukan untuk menemukan parameter optimal yang mampu menghasilkan performa model terbaik saat diuji pada data validasi. Pada tahap awal, eksplorasi optimasi dalam analisis ini mengkaji dua strategi pencarian *hyperparameter* utama, yaitu:

- a. Grid Search Cross Validation: mencari seluruh kombinasi nilai hyperparameter dalam ruang pencarian yang telah ditentukan secara eksplisit. Metode ini menjamin pencarian yang komprehensif namun membutuhkan komputasi yang lebih besar.

- b. Random Search Cross Validation: mengambil sampel kombinasi hyperparameter secara acak dari distribusi yang ditentukan. Metode ini lebih efisien secara komputasi dan sering kali menghasilkan performa yang tidak jauh berbeda dari Grid Search.

Setelah melakukan pengujian dan perbandingan terhadap kedua strategi tersebut, analisis ini pada akhirnya memutuskan untuk memilih dan menggunakan konfigurasi hasil dari Randomized Search Cross Validation. Keputusan ini diambil karena hasil eksperimen menunjukkan bahwa strategi acak tersebut justru berhasil menemukan kombinasi parameter yang menghasilkan nilai kesalahan prediksi (*Mean Absolute Percentage Error* atau MAPE) yang lebih rendah dibandingkan hasil dari *Grid Search*. Dengan demikian, model *Tuned XGBoost* yang digunakan dalam *project* ini dibangun menggunakan basis parameter hasil optimasi *Randomized Search* demi mencapai tingkat akurasi prediksi penjualan yang lebih optimal dan efisien.

3.7 Metrik Evaluasi

Evaluasi performa model regresi dilakukan menggunakan beberapa metrik yang saling melengkapi. Penggunaan lebih dari satu metrik penting dilakukan karena setiap metrik mengukur aspek yang berbeda dari kesalahan prediksi model. Metrik evaluasi yang digunakan dalam penelitian ini adalah:

- a. *Mean Absolute Error* (MAE)

Mean Absolute Error (MAE) merupakan metrik evaluasi yang digunakan untuk mengukur rata-rata dari besaran kesalahan absolut antara nilai yang diprediksi oleh model dan nilai aktual. Keunggulan metrik MAE adalah kemampuannya dalam memberikan interpretasi linear yang lugas, karena nilai kesalahan yang dihasilkan berada dalam satuan unit yang sama persis dengan variabel target penelitian (*sales_revenue_usd*). MAE juga bersifat lebih toleran dan tidak terlalu sensitif terhadap *outlier*. Secara matematis, formula untuk menghitung nilai MAE didefinisikan sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- b. *Mean Squared Error* (MSE)

Mean Squared Error (MSE) adalah metrik evaluasi yang mengukur rata-rata dari kuadrat selisih antara nilai yang diprediksi oleh model dan nilai aktual yang sebenarnya. Karakteristik utama dari metrik ini terletak pada pemberian bobot penalti yang jauh lebih

besar terhadap kesalahan (*error*) prediksi yang bernilai besar jika dibandingkan dengan MAE. Hal tersebut terjadi karena adanya proses pengkuadratan pada setiap selisih nilai, sehingga membuat MSE menjadi sangat sensitif terhadap keberadaan *outlier*. Metrik ini sangat efektif digunakan apabila peneliti ingin memastikan bahwa model yang dibangun benar-benar meminimalkan kesalahan prediksi yang fatal. Secara matematis, formula untuk menghitung nilai MSE didefinisikan sebagai berikut:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

c. *Root Mean Squared Error* (RMSE)

Root Mean Squared Error (RMSE) merupakan metrik evaluasi standar yang digunakan untuk mengukur tingkat kesalahan atau sebaran galat dari hasil prediksi suatu model regresi. Nilai RMSE diperoleh dengan cara menghitung akar kuadrat dari rata-rata selisih kuadrat antara nilai yang diprediksi oleh model dan nilai aktual yang sebenarnya. Melalui proses pengakaran tersebut, RMSE berhasil mengembalikan dimensi nilai kesalahan ke dalam satuan unit yang sama persis dengan variabel target yang sedang diteliti, sehingga hasil evaluasinya menjadi lebih intuitif dan mudah untuk diinterpretasikan secara riil.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

d. R^2 Score (Coefficient of Determination)

R^2 mengukur proporsi variansi variabel target yang mampu dijelaskan oleh model. Nilai R^2 berkisar antara 0 hingga 1 (atau negatif untuk model yang sangat buruk), di mana nilai mendekati 1 menunjukkan model yang semakin baik dalam menjelaskan variansi data. Formula R^2 adalah:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

e. *Mean Absolute Percentage Error* (MAPE)

Mean Absolute Percentage Error (MAPE) merupakan metrik evaluasi yang mengukur rata-rata persentase kesalahan absolut antara hasil prediksi model dengan nilai

aktual yang sebenarnya. Keunggulan utama dari MAPE terletak pada skalabilitasnya, di mana nilai kesalahan disajikan dalam bentuk persentase relatif, sehingga sangat berguna untuk membandingkan performa model pada beberapa *dataset* atau variabel yang memiliki skala nilai berbeda.

Dalam penelitian ini, MAPE menjadi metrik yang dititikberatkan sebagai acuan utama dalam menilai keandalan model prediksi. Penekanan pada metrik ini didasarkan pada kebutuhan praktis industri pemasaran, di mana evaluasi kesalahan dalam bentuk persentase jauh lebih mudah dipahami secara bisnis oleh pemangku kebijakan (*stakeholders*) untuk mengukur tingkat akurasi peramalan pendapatan. Semakin mendekati angka nol persen nilai MAPE yang dihasilkan, maka semakin tinggi tingkat akurasi dan presisi model yang dibangun. Secara matematis, formula untuk menghitung nilai MAPE didefinisikan sebagai berikut:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

MAPE tidak dapat digunakan apabila terdapat nilai aktual yang bernilai nol dalam dataset, sehingga penggunaannya disesuaikan dengan karakteristik variabel target.

Tabel 3.1 Metrik evaluasi beserta interpretasinya

Metrik	Interpretasi
MAE	Rata-rata kesalahan absolut
MSE	Rata-rata kuadrat kesalahan
RMSE	Akar rata-rata kuadrat kesalahan
R ²	Proporsi variansi yang dijelaskan
MAPE	Kesalahan dalam persentase

Model terbaik dipilih berdasarkan nilai MAPE terendah dan R² tertinggi secara simultan. Apabila terdapat tradeoff antara kompleksitas model dan performa, dipilih model yang memberikan keseimbangan terbaik antara akurasi prediksi, interpretabilitas, dan efisiensi komputasi.

BAB IV HASIL DAN PEMBAHASAN

4.1 Eksplorasi Data (EDA)

Sebelum melakukan pemodelan prediktif yang lebih mendalam, tahapan eksplorasi data (*exploratory data analysis*) dilakukan guna memahami karakteristik, sebaran, serta struktur fundamental dari *Marketing Sales Dataset* yang digunakan. Proses eksplorasi ini melibatkan analisis komprehensif terhadap seluruh fitur yang menyusun struktur data penelitian. Secara spesifik, *dataset* ini terdiri dari 23 variabel, yang terbagi menjadi 1 variabel dependen atau target (*Y*) berupa nilai pendapatan penjualan (*sales_revenue_usd*), serta 22 variabel independen atau fitur prediktor (*X*) yang mencakup berbagai dimensi operasional, profil demografis, dan strategi pemasaran perusahaan. Pembedahan awal terhadap seluruh variabel tersebut diawali melalui pendekatan statistika deskriptif guna memetakan nilai pemusatan dan penyebaran data secara objektif, sebagaimana dijabarkan pada bagian berikut.

4.1.1 Statistika Deskriptif


Analisis statistika deskriptif dilakukan untuk memberikan gambaran umum mengenai karakteristik empiris dari seluruh variabel yang digunakan dalam penelitian ini. Melalui pendekatan ini, informasi numerik dari variabel dependen (*Y*) dan variabel independen (*X*) dibedah secara objektif untuk melihat nilai pemusatan serta persebaran datanya. Indikator statistik yang dimuat meliputi nilai minimum, nilai maksimum, rata-rata (*mean*), median, hingga standar deviasi guna mendeteksi variabilitas serta kecenderungan awal dari distribusi data pemasaran tersebut. Rangkuman nilai statistik deskriptif untuk keseluruhan fitur dalam *dataset* disajikan secara mendetail pada Tabel 4.1 berikut.

Tabel 4.1 Statistika Deskriptif Variabel Numerik Utama

Variabel	Mean	Std. Dev	Min	Median	Max
marketing_budget_usd	9.811,01	17.064,45	500,00	4.821,40	355.979,02
ad_spend_online_usd	3.957,72	6.834,12	100,60	1.830,56	123.513,86
ad_spend_offline_usd	2.448,28	4.604,80	50,56	1.129,74	101.514,82
website_traffic	24.134,62	57.829,06	100,00	8.117,50	1.044.405,00
social_media_followers	22.158,47	117.778,90	100,00	2.866,50	5.000.000,00
conversion_rate	0,09	0,06	0,00	0,08	0,43
customer_age	45,91	16,29	18,00	46,00	74,00
customer_satisfaction_score	3,48	0,87	2,00	3,50	5,00
sales_revenue_usd (target)	5.815,30	5.639,20	680,83	4.318,01	140.790,93

4.1.2 Distribusi Variabel Target

Analisis terhadap distribusi variabel target, yaitu *sales_revenue_usd*, dilakukan secara mendalam untuk memahami bagaimana pola penyebaran nilai pendapatan penjualan yang terbentuk di dalam *dataset*. Pemahaman mengenai bentuk sebaran variabel dependen ini sangat krusial, sebab karakteristik distribusi seperti kemiringan (*skewness*) atau keberadaan nilai-nilai ekstrem akan memengaruhi perilaku dan performa algoritma regresi yang diterapkan. Melalui visualisasi data, dapat diidentifikasi kecenderungan pemusatan data pendapatan serta fluktuasi transaksi yang terjadi pada aktivitas pemasaran perusahaan. Gambaran visual mengenai bentuk distribusi dari variabel target ini disajikan secara komprehensif pada Gambar 4.1 berikut.




Gambar 4.1 Visualisasi Histogram pada Variabel Target

Berdasarkan Gambar 4.1 dapat diidentifikasi secara jelas bahwa distribusi data pendapatan penjualan tidak membentuk kurva normal, melainkan menunjukkan pola kemiringan positif yang sangat signifikan. Mayoritas frekuensi data menumpuk sangat padat di sisi kiri pada rentang nilai pendapatan yang cenderung rendah hingga menengah, yaitu berkisar antara 0 hingga sekitar 20.000 USD. Fenomena ini mengindikasikan bahwa sebagian besar transaksi operasional pemasaran yang terjadi menghasilkan nilai pendapatan dalam skala yang relatif kecil dan stabil. Di sisi lain, ekor distribusi (*tail*) melandai secara panjang ke arah kanan hingga mencapai nilai transaksi ekstrem di atas 100.000 USD. Keberadaan nilai-nilai ekstrem di sisi kanan ini mencerminkan adanya segmen transaksi bernilai sangat tinggi yang terjadi dalam frekuensi yang sangat jarang.

4.1.3 Analisis *Outlier* Variabel Target

Identifikasi terhadap keberadaan *outlier* dilakukan khusus pada variabel target *sales_revenue_usd* untuk mendeteksi adanya nilai-nilai ekstrem yang berada di luar rentang sebaran data normal. Langkah ini merupakan kelanjutan dari analisis distribusi sebelumnya, mengingat grafik histogram telah mengindikasikan adanya ekor distribusi yang memanjang ke arah kanan (*right-skewed*). Deteksi pencilan secara visual diterapkan menggunakan metode *box plot* berbasis rentang interkuartil (*Interquartile Range* atau IQR). Melalui pendekatan ini, batas atas dan batas bawah teoretis dari pendapatan penjualan dapat ditentukan secara matematis, sehingga transaksi-transaksi yang bernilai tidak wajar atau terlampau tinggi dapat dipetakan secara objektif. Visualisasi *box plot* yang menunjukkan sebaran pencilan pada variabel target disajikan pada Gambar 4.2 berikut.



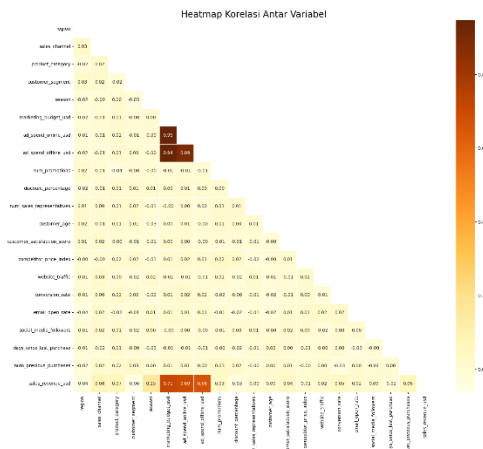
Gambar 4.2 Visualisasi BoxPlot pada Variabel Target

Berdasarkan Gambar 4.2, konfirmasi mengenai keberadaan data ekstrem dapat dipetakan secara objektif. Kotak utama yang merepresentasikan rentang interkuartil (IQR) serta garis median terlihat berada sangat rendah di bagian bawah grafik, yakni di bawah rentang nilai 20.000 USD. Posisi kotak yang memadat di area bawah ini menegaskan kembali bahwa distribusi data terpusat secara konsisten pada transaksi-transaksi bernilai kecil hingga menengah. Sementara itu, indikasi *outlier* terlihat sangat jelas melalui sebaran titik-titik lingkaran hitam yang berada di atas garis batas atas, dimulai dari nilai transaksi di kisaran 15.000 USD hingga menumpuk padat menuju ke atas. Kemudian, visualisasi memperlihatkan beberapa nilai ekstrem yang letaknya terisolasi sangat jauh di atas sebaran data lainnya, dengan nilai tertinggi menembus angka 140.000 USD.

Dalam konteks pemodelan, keberadaan *outlier* yang diidentifikasi sengaja tidak dilakukan penanganan seperti pemangkasan atau penghapusan data, karena tindakan tersebut dikhawatirkan akan menghilangkan informasi berharga mengenai karakteristik transaksi riil bernilai tinggi. Fenomena pencilan ini mencerminkan realitas bisnis di mana segmen pelanggan tertentu mampu memberikan kontribusi pendapatan yang sangat signifikan bagi perusahaan. Oleh karena itu, keberadaan data ekstrem ini dipertahankan dan menjadi alasan mendasar mengapa metrik seperti MAE dan MAPE tetap dihitung sebagai pendamping MSE/RMSE, mengingat MAE dan MAPE lebih tangguh serta tidak bias terhadap tarikan nilai ekstrem tersebut.

4.1.4 Analisis Korelasi Antarvariabel

Guna memahami kekuatan dan arah hubungan linear antara variabel independen dan variabel dependen, dilakukan analisis korelasi menggunakan metode koefisien korelasi *Pearson*. Analisis ini divisualisasikan dalam bentuk matriks korelasi berformat *heatmap* untuk mempermudah identifikasi pola hubungan antarfitur secara simultan. Melalui pemetaan ini, peneliti dapat mendeteksi variabel prediktor mana saja yang memiliki asosiasi linear kuat terhadap pendapatan penjualan (*sales_revenue_usd*). Selain itu, evaluasi melalui *heatmap* ini juga berfungsi sebagai instrumen diagnostik awal untuk mengidentifikasi potensi adanya multikolinearitas, yaitu kondisi korelasi yang terlampau tinggi antarvariabel independen itu sendiri yang dapat mengganggu stabilitas estimasi model regresi. Visualisasi matriks korelasi *heatmap* untuk seluruh variabel dalam penelitian ini disajikan pada Gambar 4.3 berikut.



Gambar 4.3 Visualisasi Heatmap Korelasi

Berdasarkan Gambar 4.3, terdapat dua temuan utama terkait hubungan antarvariabel dalam *dataset*. Pertama, terindikasi adanya masalah multikolinearitas yang sangat kuat pada beberapa variabel independen. Hal ini terlihat dari koefisien korelasi yang sangat tinggi antara *ad_spend_online_usd* dengan *marketing_budget_usd* (0,95), *ad_spend_offline_usd* dengan *marketing_budget_usd* (0,94), serta antara *ad_spend_offline_usd* dengan *ad_spend_online_usd* (0,89). Hubungan yang terlampaui kuat ini menunjukkan adanya redundansi informasi antarfitur anggaran iklan tersebut.

Kedua, terlihat bahwa mayoritas variabel independen lainnya memiliki korelasi linear yang sangat rendah (mendekati 0) terhadap variabel target *sales_revenue_usd*. Hanya variabel terkait anggaran seperti *marketing_budget_usd* (0,71), *ad_spend_online_usd* (0,69), dan *ad_spend_offline_usd* (0,66) yang menunjukkan korelasi positif kuat dengan variabel target. Sementara itu, fitur-fitur lain seperti *customer_age*, *num_sales_representatives*, hingga *website_traffic* memiliki nilai korelasi yang hampir flat terhadap variabel target.

4.2 Prapemrosesan Data

Setelah dilakukan eksplorasi data awal, tahapan prapemrosesan data (*data preprocessing*) dilaksanakan untuk memastikan bahwa seluruh data yang akan dimasukkan ke dalam model *machine learning* berada dalam kondisi bersih, konsisten, dan siap latih. Berdasarkan hasil temuan pada analisis eksploratif sebelumnya, prapemrosesan menjadi sangat krusial untuk meningkatkan kualitas data sehingga model dapat memperoleh pola informasi secara optimal. Proses pembersihan dan penyiapan data dalam analisis ini dilakukan melalui beberapa tahapan sistematis secara berurutan. Evaluasi dan tindakan teknis tersebut meliputi pemeriksaan data yang hilang (*missing values*), identifikasi data duplikat, hingga transformasi skala data yang seluruhnya dijabarkan secara mendetail pada bagian di bawah ini.

4.2.1 Feature Selection

Tahapan seleksi fitur dilakukan dengan tujuan untuk menghapus fitur-fitur yang tidak memberikan kontribusi signifikan terhadap prediksi variabel target. Keputusan seleksi fitur dalam penelitian ini didasarkan secara objektif pada hasil analisis matriks korelasi yang telah disajikan sebelumnya pada Gambar 4.3. Berdasarkan evaluasi terhadap Gambar 4.3, ditemukan dua kondisi utama yang mendasari penyusutan jumlah variabel prediktor.

Pertama, untuk mengatasi masalah multikolinearitas akut yang terdeteksi antara fitur *ad_spend_online_usd*, *ad_spend_offline_usd*, dan *marketing_budget_usd*, dilakukan tindakan eliminasi. Dalam analisis ini memutuskan untuk menghapus fitur *ad_spend_online_usd* dan *ad_spend_offline_usd*, serta hanya mempertahankan variabel *marketing_budget_usd* sebagai satu-satunya variabel makro yang merepresentasikan total alokasi anggaran pemasaran. Langkah ini diambil untuk mencegah terjadinya instabilitas numerik pada model akibat pembagian informasi yang tumpang tindih.

Kedua, variabel independen yang menunjukkan nilai koefisien korelasi linear yang sangat rendah (mendekati nol) terhadap variabel target *sales_revenue_usd*, diputuskan untuk dikeluarkan dari ruang pemodelan. Variabel-variabel tersebut dinilai hanya akan menjadi *noise* yang dapat menurunkan kemampuan generalisasi model. Melalui proses penyaringan yang ketat ini, dari total awal 22 variabel independen, analisis ini secara final hanya menyisakan 7 fitur prediktor terbaik untuk digunakan dalam proses pelatihan model *machine learning*, dengan tetap mempertahankan 1 variabel target.

4.2.2 Identifikasi Missing Value

Berdasarkan hasil pengujian dengan bantuan komputasi, diperoleh bahwa 1 variabel target beserta 7 fitur prediktor yang telah terpilih secara final memiliki persentase kelengkapan data sebesar 100%. Dengan kata lain, tidak ditemukan adanya *missing value* sama sekali pada seluruh variabel tersebut. Karena kondisi data sudah sepenuhnya terisi dan utuh, penelitian ini tidak melakukan tindakan penanganan atau imputasi data tambahan. Hal ini menjamin bahwa orisinalitas dan integritas sebaran nilai pada fitur-fitur final tetap terjaga dengan baik untuk proses pemodelan selanjutnya.

4.2.3 Identifikasi Data Duplikat

Berdasarkan hasil pengujian terhadap 7 fitur dan 1 variabel target yang tersisa, diperoleh hasil bahwa tidak ditemukan adanya rekaman data yang ganda atau duplikat pada keseluruhan baris *dataset*. Seluruh baris transaksi telah terverifikasi bersifat unik. Oleh karena itu, analisis ini tidak melakukan tindakan penanganan berupa penghapusan atau reduksi baris data lebih lanjut. Kondisi ini memastikan bahwa integritas jumlah sampel data tetap terjaga secara utuh untuk masuk ke tahapan pemodelan selanjutnya.

4.2.4 Transformasi Skala Data

Setelah seluruh fitur prediktor numerik ditransformasikan menggunakan metode *RobustScaler*, analisis statistika deskriptif kembali dilakukan terhadap data hasil transformasi tersebut. Langkah ini bertujuan untuk memverifikasi secara empiris perubahan karakteristik distribusi, nilai pemusatan, serta rentang variabilitas baru yang terbentuk pada 7 fitur prediktor setelah disesuaikan menggunakan parameter median dan rentang interkuartil (IQR). Melalui evaluasi ulang ini, dapat dipastikan bahwa skala antarvariabel kini telah seragam dan bebas dari dominasi absolut angka-angka besar, namun dengan tetap mempertahankan eksistensi nilai pencilan asli di dalamnya. Rangkuman nilai statistik deskriptif final yang siap digunakan sebagai input dalam tahapan pemodelan disajikan pada Tabel 4.2 berikut.

Tabel 4.2 Statistika Deskriptif Fitur Numerik setelah Standarisasi

Count	Min	Max	Median	Mean
marketing_budget_usd	-0,496	40,280	0,000	0,572
conversion_rate	-1,049	4,795	0,000	0,161
num_previous_purchases	-1,666	3,000	0,000	-0,007

Berdasarkan Tabel 4.2, terlihat hasil transformasi dari penerapan metode *RobustScaler*. Indikator utama keberhasilan proses ini ditunjukkan oleh nilai median pada ketiga fitur (*marketing_budget_usd*, *conversion_rate*, dan *num_previous_purchases*) yang kini tepat bernilai 0,000. Kondisi ini membuktikan bahwa titik pusat data telah berhasil diselaraskan pada nilai median masing-masing variabel asli.

Selain itu, rentang nilai minimum (*min*) dan maksimum (*max*) menunjukkan bahwa skala data telah diperkecil secara proporsional tanpa menghilangkan karakteristik pencilan asli. Sebagai contoh, fitur *marketing_budget_usd* memiliki nilai maksimum yang sangat besar mencapai 40,280 dengan nilai rata-rata (*mean*) sebesar 0,572 yang berada di atas median. Nilai rata-rata yang lebih besar dari median serta nilai maksimum yang tinggi mengonfirmasi secara empiris bahwa data masih mempertahankan struktur pencilan positif (*right-skewed*) bawaannya, namun kini berada dalam rentang skala yang aman dan siap melanjutkan tahap pemodelan.

4.3 Pemodelan

Pada tahap pemodelan, dilakukan pembangunan beberapa model regresi *machine learning* untuk memprediksi pendapatan penjualan (*sales_revenue_usd*) berdasarkan data yang telah melalui proses *preprocessing*. Model yang digunakan terdiri atas Regresi Linier Berganda sebagai model *baseline*, serta Random Forest Regressor, Lasso Regressor, dan XGBoost Regressor sebagai model pembanding. Penggunaan Regresi Linier Berganda sebagai *baseline* bertujuan untuk memberikan acuan awal dalam menilai peningkatan performa model yang lebih kompleks. Selanjutnya, ketiga model lainnya digunakan untuk mengeksplorasi pendekatan yang berbeda dalam menangkap pola hubungan antara variabel prediktor dan pendapatan penjualan. Kinerja masing-masing model kemudian dievaluasi dan dibandingkan menggunakan metrik MAE, MAPE, RMSE, dan R^2 untuk menentukan model dengan performa prediksi terbaik.

4.3.1 Perbandingan Kinerja Model

Untuk mengevaluasi kemampuan prediksi masing-masing model, dilakukan perbandingan kinerja antara model *baseline* dan model *machine learning* yang dikembangkan. Regresi Linier Berganda digunakan sebagai model *baseline* karena merupakan model yang sederhana dan umum digunakan dalam permasalahan prediksi. Selanjutnya, performa model *baseline* dibandingkan dengan beberapa model lain, yaitu XGBoost Regressor, Random Forest Regressor, dan Lasso Regressor menggunakan metrik evaluasi berupa Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), Root Mean Square Error (RMSE), dan koefisien determinasi (R^2).

Tabel 4.3 Perbandingan Metrik Evaluasi

Model	MAE	MAPE	RMSE	R^2
Linear Regression (Baseline)	2494,48	0,565	3560,9	0,599
Random Forest Regressor	880,455	0,159	1654,214	0,913
Lasso Regression	2494,48	0,565	3560,9	0,599
XGBoost Regressor	826,135	0,146	2460,699	0,808

Berdasarkan hasil pengujian yang disajikan pada Tabel 4.1, dilakukan analisis komparatif antara model komputasi yang dibangun dengan model acuan (*baseline*). Hasil evaluasi menunjukkan adanya perbedaan performa yang signifikan antara kelompok model linier (*Linear Regression* dan *Lasso Regression*) dengan kelompok model berbasis pohon

(*Random Forest Regressor* dan *XGBoost Regressor*). Mengingat fokus utama penelitian ini adalah untuk menghasilkan prediksi pendapatan yang aplikatif bagi pihak manajemen, maka *Mean Absolute Percentage Error* (MAPE) ditetapkan sebagai metrik acuan utama. Pemilihan MAPE didasarkan pada karakteristiknya yang merepresentasikan galat dalam satuan persentase, sehingga jauh lebih mudah diinterpretasikan secara intuitif dalam konteks bisnis dibandingkan metrik absolut seperti MAE atau RMSE.

Ditinjau dari metrik utama tersebut, algoritma *XGBoost Regressor* berhasil mencatatkan performa terbaik dengan nilai MAPE terkecil, yaitu sebesar 0,146. Hal ini mengindikasikan bahwa rata-rata penyimpangan prediksi yang dihasilkan oleh *XGBoost* hanya sebesar 14,6% dari nilai riilnya, disusul oleh *Random Forest Regressor* dengan tingkat galat sebesar 15,9%. Sementara itu, kelompok model linier berada di posisi terbawah dengan tingkat eror yang cukup tinggi mencapai 56,5%. Berdasarkan keunggulan nilai MAPE yang paling efisien tersebut, algoritma *XGBoost Regressor* resmi dipilih sebagai model terbaik (*champion model*) dalam penelitian ini yang akan dilanjutkan ke tahapan optimasi melalui proses *hyperparameter tuning* guna mendongkrak akurasi prediksi ke titik yang lebih maksimal.

Fenomena unik lain yang ditemukan dalam eksperimen awal ini adalah kesamaan nilai metrik evaluasi yang sangat identik antara *Linear Regression* dan *Lasso Regression*, di mana keduanya menghasilkan nilai MAPE sebesar 0,565 dan R^2 sebesar 0,599. Kemiripan performa hingga beberapa angka di belakang koma ini terjadi karena karakteristik *dataset* pemasaran yang digunakan telah melalui proses prapemrosesan data (*data cleaning* dan *feature selection*) yang sangat optimal pada tahapan sebelumnya. Ketika sebuah dataset sudah bersih dari fitur-fitur redundan yang memiliki korelasi tinggi, fungsi penalti L1 (*Lasso Penalty*) tidak lagi melakukan eliminasi atau penyusutan koefisien prediktor secara agresif. Akibatnya, bobot koefisien yang dihasilkan oleh algoritma *Lasso* akan konvergen dan berperilaku sama persis dengan metode kuadrat terkecil standar (*Ordinary Least Squares*) pada *Linear Regression*.

4.3.2 Optimasi *Hyperparameter* Model *XGBoost*

Setelah menetapkan *XGBoost Regressor* sebagai algoritma terbaik berdasarkan tingkat kesalahan persentase terendah, tahapan analisis dilanjutkan dengan melakukan optimasi melalui proses *hyperparameter tuning*. Langkah optimasi ini dilakukan dengan tujuan untuk

mencari kombinasi parameter terbaik yang dapat meminimalkan nilai galat lebih lanjut serta mencegah terjadinya kondisi *overfitting* pada model. Proses pencarian parameter optimal ini difokuskan pada pengaturan beberapa parameter kunci, seperti tingkat pembelajaran (*learning rate*), kedalaman maksimum pohon (*max_depth*), serta jumlah estimator (*n_estimators*). Pengujian hasil optimasi ini tetap diukur secara objektif menggunakan data uji yang sama agar diperoleh perbandingan yang valid dan adil. Perubahan performa serta efisiensi akurasi model *XGBoost Regressor* sebelum dan sesudah dilakukan proses *hyperparameter tuning* disajikan secara komparatif pada Tabel berikut.

Tabel 4.4 Perbandingan Evaluasi Sebelum dan Sesudah Hyperparameter Tuning

Model	MAE	MAPE	RMSE	R ²
XGBoost Regressor	826,135	0,146	2460,699	0,808
XGBoost Regressor (Tuned)	745,87	0,136	2411,5	0,816

Kombinasi parameter optimal yang ditemukan melalui *RandomizedSearchCv()* adalah {'colsample_bytree': 0.9387, 'gamma': 0.4282, 'learning_rate': 0.0909, 'max_depth': 3, 'n_estimators': 727, 'reg_alpha': 0.0421, 'subsample': 0.6647}. Nilai-nilai ini memberikan penjelasan logis terhadap pembentukan struktur model yang efisien. Parameter *max_depth* yang bernilai 3 menunjukkan bahwa pohon keputusan yang terbentuk sengaja dibuat dangkal untuk menghindari kompleksitas berlebih. Kedalaman yang rendah ini dikompensasi secara optimal oleh jumlah estimator yang besar (*n_estimators*: 727) dengan tingkat pembelajaran yang lambat namun konsisten (*learning_rate*: 0.0909), sehingga model melakukan koreksi kesalahan secara bertahap tanpa menghafal data latihan secara berlebihan (*overfitting*). Selain itu, nilai *gamma* (0.4282) dan *reg_alpha* (0.0421) bertindak sebagai fungsi regularisasi ketat yang membatasi pemisahan *node* dan bobot daun yang terlalu ekstrem. Terakhir, kombinasi *subsample* (0.6647) dan *colsample_bytree* (0.9387) memasukkan unsur acak dengan membatasi jumlah baris data yang digunakan.

Melalui penerapan kombinasi parameter terbaik tersebut, eksperimen komputasi secara signifikan berhasil meningkatkan akurasi dan meminimalkan tingkat galat pada model *XGBoost Regressor* sebagaimana disajikan pada Tabel 4.3. Indikator keberhasilan proses *hyperparameter tuning* ini dibuktikan oleh penurunan nilai metrik acuan utama, yaitu *Mean*

Absolute Percentage Error (MAPE), sebesar 1% dari nilai awal 0,146 (14,6%) menyusut menjadi 0,136 (13,6%). Reduksi tingkat kesalahan persentase ini juga berjalan selaras dengan penurunan nilai MAE menjadi 745,87 dan RMSE menjadi 2411,5. Lebih jauh lagi, kemampuan model dalam menjelaskan variansi data (*R-squared*) mengalami penguatan dari angka 0,808 merangkak naik ke angka 0,816. Hasil ini menegaskan bahwa penyesuaian parameter ke titik optimal terbukti efektif melahirkan model prediksi akhir yang memiliki tingkat presisi dan generalisasi yang jauh lebih baik.

4.4 Analisis dan Evaluasi Model Terpilih

Setelah melalui tahapan optimasi parameter dan berhasil menetapkan model *XGBoost Regressor (Tuned)* sebagai model akhir terbaik, analisis selanjutnya difokuskan pada pengujian kualitas serta validitas hasil prediksi secara lebih mendalam. Evaluasi komprehensif ini dilakukan melalui tiga pendekatan utama guna memastikan model tidak hanya unggul dari segi angka metrik, melainkan juga stabil secara teoretis. Pendekatan pertama dilakukan dengan membandingkan secara visual penyebaran antara nilai aktual data lapangan dengan nilai hasil prediksi model (*actual vs predicted plot*). Selanjutnya, dilakukan analisis residual untuk memeriksa distribusi nilai galat guna memastikan tidak adanya pola bias yang sistematis pada hasil estimasi. Akhirnya, evaluasi ditutup dengan analisis kurva pembelajaran (*learning curve*) untuk mendeteksi stabilitas performa model dalam mengenali pola data seiring dengan bertambahnya intensitas sampel latihan.

4.4.1 Plot Prediksi dan Aktual




Gambar 4.4 Perbandingan Plot Prediksi dan Aktual

Grafik pada Gambar 4.4 menunjukkan sebaran antara nilai prediksi dan nilai aktual *sales_revenue_usd* untuk model *XGBoost* yang telah dituning, dengan garis putus-putus merah merepresentasikan kondisi prediksi sempurna (prediksi = aktual). Pada rentang

pendapatan rendah hingga menengah (kurang lebih di bawah 20.000 USD), titik-titik data mengelompok rapat di sekitar garis diagonal, menunjukkan bahwa model mampu memprediksi nilai penjualan dengan cukup akurat untuk mayoritas transaksi.

Namun, sebaran titik mulai melebar pada rentang pendapatan yang lebih tinggi (di atas 30.000 USD). Beberapa titik pada rentang ini berada cukup jauh dari garis diagonal, mengindikasikan kesalahan prediksi yang lebih besar pada transaksi bernilai tinggi. Kasus paling ekstrem terlihat pada satu titik dengan nilai aktual sekitar 90.000 USD, tetapi model hanya memprediksi sekitar 22.000 USD dengan selisih sekitar 68.000 USD.

4.4.2 Analisis Residual




Gambar 4.5 Visualisasi Residual Model XGBoost Tuned

Berdasarkan Gambar 4.5 bagian kiri mengenai distribusi dari residual model, diperoleh gambaran statistik bahwa nilai rata-rata galat (*mean*) berada di angka 61,55 dengan standar deviasi sebesar 2410,72. Secara visual, kurva distribusi residual menunjukkan bentuk yang cenderung asimetris dan "berat di sebelah kanan" (*positive skewness*). Karakteristik ini diperkuat secara matematis melalui nilai *skewness* yang cukup tinggi yaitu sebesar 22,59 serta nilai kurtosis ekstrem mencapai 634,23. Nilai kurtosis yang sangat tinggi (*leptokurtik*) ini mengonfirmasi adanya ekor distribusi yang panjang di sisi kanan, yang mengindikasikan bahwa model *XGBoost (Tuned)* beberapa kali menghasilkan nilai eror positif yang sangat besar pada sejumlah kecil sampel data.

Selanjutnya, analisis dilakukan pada Gambar 4.5 bagian kanan yang menggambarkan hubungan antara residual dengan nilai prediksi. Hasil visualisasi memperlihatkan bahwa

persebaran titik galat tidak sepenuhnya merata, melainkan membentuk pola yang melebar seiring bertambahnya nilai prediksi (pola kerucut), serta menyisakan satu titik pencilan (*outlier*) ekstrem di atas nilai residual 60.000. Kondisi ini mengindikasikan adanya gejala heteroskedastisitas, di mana varians dari galat model tidak konstan. Munculnya indikasi heteroskedastisitas dan keberadaan *outlier* ini merupakan dampak langsung dari keputusan metodologis di awal penelitian, di mana data ekstrem pada *dataset* asli memang sengaja tidak dibuang atau dieliminasi agar model dapat mempelajari kondisi riil fluktuasi nilai pendapatan penjualan secara apa adanya. Akibatnya, meskipun algoritma *XGBoost* sudah dioptimasi, sisa-sisa pola dari data ekstrem tersebut tetap tercermin di dalam komponen residual model.

4.4.3 Feature Importance




Gambar 4.6 Visualisasi Tingkat Pengaruh Fitur terhadap Variabel Target

Analisis tingkat kepentingan fitur (*feature importance*) pada model *Tuned XGBoost Regressor* dilakukan untuk mengukur kontribusi relatif dari masing-masing variabel prediktor dalam memprediksi variabel target *sales_revenue_usd*. Berdasarkan nilai bobot kepentingan yang dihasilkan oleh model, variabel *customer_segment* teridentifikasi sebagai fitur dengan tingkat kontribusi tertinggi, yaitu sebesar 0,3439 (34,39%), diikuti secara ketat oleh variabel *marketing_budget_usd* di posisi kedua dengan nilai koefisien sebesar 0,3287 (32,87%). Dominasi kedua variabel ini menunjukkan bahwa segmentasi konsumen dan besaran anggaran pemasaran merupakan dua pilar utama yang memegang kendali paling besar dalam struktur keputusan algoritma untuk mengestimasi pendapatan penjualan.

Variabel pendukung lainnya yang bersifat musiman dan kategorikal juga memberikan kontribusi yang cukup berarti bagi performa model. Fitur *season* mencatatkan nilai kepentingan sebesar 0,1333 (13,33%), disusul oleh *product_category* sebesar 0,0950 (9,50%) dan *sales_channel* sebesar 0,0500 (5,00%). Sebaliknya, variabel numerik seperti *num_previous_purchases* dan *conversion_rate* justru memberikan kontribusi yang relatif kecil terhadap keputusan model, dengan nilai koefisien masing-masing hanya sebesar 0,0296 (2,96%) dan 0,0195 (1,95%). Meskipun berada di posisi terbawah, variabel-variabel tersebut tetap dipertahankan karena memberikan informasi mikro tambahan yang membantu model menangkap variasi kecil pendapatan pada pola transaksi pelanggan individu.

Temuan ini menegaskan secara strategis bahwa dalam arsitektur non-linear XGBoost, pengenalan terhadap karakteristik dan perilaku pada tiap segmen pelanggan (*customer_segment*) memegang peran yang sangat krusial sebelum perusahaan mengalokasikan dana promosi (*marketing_budget_usd*). Rekomendasi bisnis yang dihasilkan dari model ini mengarahkan manajemen agar tidak hanya berfokus pada pelonjakan anggaran pemasaran secara umum, melainkan lebih memprioritaskan strategi pemasaran yang terpersonalisasi secara spesifik berdasarkan segmentasi konsumen dan momentum musiman (*season*) guna mengoptimalkan konversi pendapatan secara lebih efektif dan efisien.

4.4.4 Learning Curve



Gambar 4.7 1 Visualisasi Learning Curve Model XGBoost Tuned

Evaluasi menggunakan kurva pembelajaran (*learning curve*) dilakukan untuk menilai stabilitas model *Tuned XGBoost Regressor* serta mendeteksi adanya indikasi *overfitting* atau *underfitting* seiring dengan bertambahnya volume data pelatihan. Berdasarkan

hasil visualisasi pada Gambar 4.7, diperoleh nilai akhir galat MAPE pada data pelatihan (*training score*) sebesar 0,115 atau 11,5%, sedangkan nilai galat pada data validasi silang (*cross-validation score*) menetap di angka 0,144 atau 14,4%.

Selisih atau jarak antara kedua kurva tersebut tergolong relatif kecil, yaitu hanya sekitar 0,029 (2,9%). Kedekatan jarak ini menunjukkan bahwa performa model saat dihadapkan pada data baru yang belum pernah dilihat sebelumnya memiliki efisiensi yang tidak jauh berbeda dengan kinerjanya pada data latih. Kondisi tersebut mengindikasikan bahwa model berhasil melakukan generalisasi dengan baik dan bebas dari masalah *overfitting* yang akut, meskipun terdapat margin tipis yang dinilai wajar sebagai akibat dari karakteristik arsitektur XGBoost yang berbasis pohon kompleks.

Selain itu, pergerakan kedua kurva yang bergerak saling mendekati (*konvergen*) dan mulai mendatar (*plateau*) ketika ukuran data pelatihan menyentuh di atas 2.500 sampel menandakan bahwa model telah mencapai titik jenuh optimalnya. Pola konvergensi ini memberikan petunjuk penting bahwa penambahan volume baris data baru ke dalam sistem kemungkinan besar tidak akan lagi memberikan kontribusi peningkatan performa yang signifikan. Oleh karena itu, jika di masa mendatang diperlukan optimasi akurasi prediksi yang lebih tinggi, fokus pengembangan sebaiknya dialihkan pada rekonstruksi kualitas fitur (*feature engineering*) atau penanganan data ekstrem (*outlier*) secara selektif, bukan dengan menambah kuantitas sampel data.

BAB V

PENUTUP

5.1 Kesimpulan

Analisis ini berhasil membangun dan membandingkan beberapa model regresi machine learning untuk memprediksi pendapatan penjualan (`sales_revenue_usd`) pada Marketing Sales Dataset, dengan menjawab lima rumusan masalah yang diajukan di awal. Strategi pemasaran terbukti memengaruhi pendapatan penjualan, tetapi pengaruhnya tidak bersifat linear sederhana. Hal ini terlihat dari performa Linear Regression dan Lasso Regression yang jauh tertinggal dibandingkan model berbasis pohon keputusan, dengan MAPE sebesar 56,5% berbanding 13,6% pada XGBoost yang telah dituning. Kesamaan nilai metrik antara Linear Regression dan Lasso juga mengindikasikan bahwa dataset sudah relatif bersih dari multikolinearitas sejak tahap seleksi fitur, sehingga penalti L1 pada Lasso tidak lagi banyak berperan menyusutkan koefisien. Dari sisi faktor yang berpengaruh, segmentasi pelanggan (`customer_segment`) dan besaran anggaran pemasaran (`marketing_budget_usd`) tampil sebagai dua variabel paling dominan, dengan kontribusi masing-masing 34,39% dan 32,87% terhadap keputusan model. Musim (`season`), kategori produk (`product_category`), dan kanal penjualan (`sales_channel`) turut berkontribusi meski dalam porsi lebih kecil, sementara jumlah pembelian sebelumnya (`num_previous_purchases`) dan tingkat konversi (`conversion_rate`) hanya memberi sumbangan informasi yang minim. Artinya, siapa pelanggannya dan seberapa besar dana yang dialokasikan untuk memasarkan produk kepada mereka jauh lebih menentukan pendapatan dibandingkan riwayat transaksi individual pelanggan itu sendiri.

Perbandingan algoritma pada konfigurasi default justru menyajikan temuan yang menarik. Random Forest Regressor mencatatkan R^2 tertinggi (0,913) dan RMSE terendah (1654,214), bahkan mengungguli XGBoost Regressor (R^2 0,808; RMSE 2460,699). Namun karena analisis ini menetapkan MAPE sebagai metrik acuan utama dengan alasan interpretasinya yang lebih intuitif bagi pihak bisnis, XGBoost Regressor yang mencatatkan MAPE terkecil (14,6%) tetap dipilih sebagai champion model untuk dilanjutkan ke tahap hyperparameter tuning. Setelah dioptimasi melalui `RandomizedSearchCV`, performanya meningkat menjadi MAPE 13,6% dan R^2 0,816, dengan MAE turun menjadi 745,87 dan RMSE menjadi 2411,5. Peningkatannya tidak besar secara angka, tapi cukup berarti karena parameter yang ditemukan (`max_depth` dangkal, `n_estimators`

besar, `learning_rate` kecil) justru mengarahkan model ke struktur yang lebih konservatif dan tidak mudah overfitting.

Soal seberapa baik model ini bekerja secara keseluruhan, hasilnya cukup positif namun belum sempurna. Model mampu memprediksi pendapatan pada rentang rendah hingga menengah (di bawah 20.000 USD) dengan cukup akurat. Akurasi ini menurun pada transaksi bernilai tinggi (di atas 30.000 USD), bahkan ditemukan satu kasus ekstrem dengan selisih prediksi mencapai 68.000 USD. Analisis residual memperkuat temuan ini: pola heteroskedastisitas dan skewness positif yang tinggi (22,59) mengindikasikan model masih kesulitan menangkap fluktuasi pendapatan pada segmen transaksi besar. Di sisi lain, `learning curve` menunjukkan jarak yang relatif kecil antara training score dan cross-validation score, hanya sekitar 2,9%, yang berarti model tidak mengalami overfitting akut dan mampu melakukan generalisasi dengan cukup baik pada data baru. Secara keseluruhan, XGBoost Regressor yang telah dituning merupakan model paling representatif untuk memprediksi pendapatan penjualan pada dataset ini, dengan catatan performanya masih perlu diwaspadai khususnya untuk transaksi bernilai tinggi.

5.2 Keterbatasan Analisis

Dalam pelaksanaan analisis ini, terdapat beberapa keterbatasan metodologis dan teknis yang perlu dicatat sebagai bahan pertimbangan dalam interpretasi hasil. Pertama, pada tahapan evaluasi residual model *Tuned XGBoost Regressor*, masih ditemukan adanya gejala heteroskedastisitas yang ditunjukkan oleh pola pelebaran galat (pola kerucut) seiring meningkatnya nilai estimasi. Model mencatatkan tingkat kesalahan prediksi yang cenderung membesar ketika memproyeksikan nilai pendapatan penjualan di atas \$20.000, serta menyisakan pencilan (*outlier*) ekstrem di atas nilai residual 60.000. Kondisi ini terjadi sebagai konsekuensi logis dari keputusan untuk tidak melakukan pembersihan atau transformasi terhadap data ekstrem pada *dataset* asli, demi mempertahankan orisinalitas fluktuasi data operasional bisnis di lapangan.

Kedua, analisis komparatif awal pada penelitian ini langsung menerapkan konfigurasi parameter standar (*default*) bawaan dari masing-masing algoritma, sehingga karakteristik performa transisi model melalui variasi parameter manual tidak dieksplorasi secara bertahap sebelum berlanjut ke tahapan optimasi otomatis. Terakhir, kesamaan hasil metrik yang sangat identik antara model *Linear Regression* dan *Lasso Regression* mengindikasikan bahwa arsitektur dataset ini memiliki struktur hubungan non-linier yang sangat kuat. Hal tersebut membatasi ruang

eksplorasi pemodelan berbasis parametrik linier dalam menangkap interaksi makro antarfitur secara lebih mendalam.

Selain itu, keterbatasan juga terdapat pada tahapan seleksi fitur (*feature selection*) yang dilakukan berbasis matriks korelasi *heatmap* pada fase eksplorasi data. Pembuatan *heatmap* tersebut dilakukan sebelum adanya penanganan nilai yang hilang (*missing value*) di dalam *dataset*. Secara komputasi, penghitungan koefisien korelasi saat menghadapi nilai *null* akan menerapkan metode penghapusan berpasangan (*pairwise deletion*), di mana baris yang mengandung nilai kosong akan diabaikan begitu saja secara otomatis. Kondisi ini berpotensi mengurangi tingkat akurasi serta objektivitas nilai korelasi yang dihasilkan, karena ukuran sampel yang digunakan dalam menghitung hubungan antar-fitur menjadi tidak konsisten dan tidak sepenuhnya merepresentasikan struktur populasi data yang sebenarnya sebelum masuk ke tahap pemodelan.

Terakhir, terdapat keterbatasan prosedural pada tahapan transformasi skala data, di mana proses standarisasi menggunakan *Robust Scaler* dilakukan pada keseluruhan repositori data sebelum dilakukannya pembagian data (*data splitting*). Prosedur ini memicu terjadinya fenomena kebocoran data (*data leakage* atau *information leakage*), sebab nilai statistik deskriptif berupa *median* dan Jangkauan Antarkuartil (IQR) yang digunakan sebagai basis penskalaan sudah melibatkan informasi dari data uji (*test set*). Kebocoran informasi ini berpotensi menyebabkan model memiliki bias evaluasi yang cenderung terlalu optimis (*overoptimistic*), karena model secara tidak langsung telah mengenali gambaran umum distribusi dari data uji sejak fase prapemrosesan data dijalankan.

5.3 Saran

Beberapa catatan berikut dapat menjadi bahan perbaikan untuk penelitian selanjutnya.

1. Isu kebocoran data (*data leakage*) akibat penerapan *Robust Scaler* sebelum *train-test split* perlu diperbaiki lebih dulu. Idealnya, parameter scaling berupa median dan IQR dihitung hanya dari data latih, baru kemudian digunakan untuk mentransformasi data uji, agar estimasi performa model tidak *overoptimistic*.
2. Urutan penanganan missing value juga sebaiknya dibalik, dilakukan sebelum membangun matriks korelasi untuk seleksi fitur. Urutan yang terbalik seperti pada penelitian ini berisiko menghasilkan nilai korelasi yang kurang representatif, karena baris dengan nilai kosong otomatis terabaikan lewat *pairwise deletion*.

3. Mengingat residual model masih menunjukkan heteroskedastisitas dan ekor distribusi yang panjang di sisi kanan, transformasi logaritmik pada variabel target, misalnya $\log(\text{sales_revenue_usd}+1)$, layak dicoba pada penelitian berikutnya. Pendekatan ini berpotensi membantu model menangani rentang nilai pendapatan yang sangat lebar tanpa harus membuang data ekstrem yang sebenarnya representatif terhadap kondisi bisnis riil.
4. Eksplorasi algoritma juga bisa diperluas ke model ensemble lain seperti LightGBM atau CatBoost, yang memiliki cara penanganan fitur kategorikal dan missing value sedikit berbeda dari XGBoost. Perbandingan yang lebih luas akan memperkuat klaim bahwa XGBoost memang pilihan terbaik, bukan sekadar karena terbatasnya pilihan algoritma yang dicoba.
5. Dari sisi praktis, hasil *feature importance* pada penelitian ini bisa menjadi dasar bagi perusahaan untuk menyusun strategi pemasaran yang lebih terarah. Alokasi dana pemasaran sebaiknya disesuaikan dengan karakteristik customer_segment dan momentum season tertentu, bukan dinaikkan secara merata ke semua segmen, karena dua faktor itulah yang paling menentukan besaran pendapatan menurut model.
6. Terakhir, karena dataset yang digunakan hanya mengambil sebagian kecil dari data asli (5.000 dari 60.000 observasi) demi efisiensi komputasi, penelitian selanjutnya bisa mencoba melatih model dengan jumlah data yang lebih besar. Penambahan ini terutama penting untuk memperkuat representasi pada transaksi bernilai tinggi, yang sampai saat ini masih sulit diprediksi secara akurat oleh model.

LAMPIRAN

Lampiran 1: Link AI yang digunakan

<https://share.gemini.google/Pl9b7HVTJorj>

<https://chat.deepseek.com/share/aux7kixfxdiwlinuj5>

<https://chatgpt.com/share/6a3e8d6d-7ef8-83ec-a3aa-ce88bf40c80c>

Lampiran 2: Link Google Colab

https://colab.research.google.com/drive/1nX9SvM8ZmMYS_b26u5Jkyca21p00zA4usp=sharing

Lampiran 2: Link Dataset

<https://www.kaggle.com/datasets/abdefattahibrahim/marketing-sales-dataset>

Lampiran 3: Link GitHub

<https://github.com/Arroja100/Project-Machine-Learning>